



如果学习时间增加，考试成绩是否也会相应提高？



如果公司的行政支出太多，是不是会造成利润率下降？



如果国内人民平均收入提高，平均寿命是否可以延长？
内在关联是什么？




Chp27 线性回归

27.1 相关系数

Coefficient of Correlation

Pg. 276




散布图(Scatter plot)

在日常生活中，许多变量之间存在着某种关系，如身高vs体重、BMI指数vs血压、风力vs雨量等。

为了观察两组数据之间的关系，将收集的成对数据标在坐标平面上。设两组数据为 $x_1, x_2, \dots, x_n$ 及 $y_1, y_2, \dots, y_n$ ，在坐标平面上标出 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 各点，所得的图为散布图。散布图是一种用于表示两组数据之间的相关程度的图。

身高 x (公分)	172	160	162	164	170	168	166
体重 y (公斤)	60	50	52	58	62	56	54



由散布图可以快速观察出两个变量之间是否有关系。

(1)正相关：两个变量大约有一致的趋势(大约同时增加或减少，见图1)

(2)负相关：两个变量趋势大约相反(一个变量增加/减少，另一个变量减少/增加，见图2)

(3)完全正相关：资料全部在一条斜率为正的直线上(见图3)

(4)完全负相关：资料全部在一条斜率为负的直线上(见图4)

(5)零相关：两个变量的变化之间无关(见图5)

以上的正相关与负相关统称为直线相关(*linearly correlated*)




图1




图2




图3





图5







图4




相关系数 (Coefficient of correlation)

虽然通过观察散布图可以看出两组数据之间的相关关系，但无法精确判断其相关程度。为了更客观地描述两组数据之间的相关程度，可通过计算相关系数。

设有 X 与 Y 的数据 n 组, $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 。 X 与 Y 的平均数分别为 $\bar{x}$ 及 $\bar{y}$ 。

如图所示，作 X 与 Y 的散布图，直线 $x = \bar{x}$ 与 $y = \bar{y}$ 将散布图划分为四个区域。

将其设想为象限，观察到：



落在第一象限的点, $(x_i - \bar{x})(y_i - \bar{y})$ 的值为正

落在第二象限的点, $(x_i - \bar{x})(y_i - \bar{y})$ 的值为负

落在第三象限的点, $(x_i - \bar{x})(y_i - \bar{y})$ 的值为正

落在第四象限的点, $(x_i - \bar{x})(y_i - \bar{y})$ 的值为负

由此定义两组数据的协方差 (covariance):

$$\sigma_{XY} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

若两组数据正相关，多数点落在第一、三象限，则 $\sigma_{XY} > 0$

若两组数据负相关，多数点落在第二、四象限，则 $\sigma_{XY} < 0$

若两组数据零相关，点平均落在四个象限，，正负抵消，则 σ_{XY} 趋近0










由于 σ_{XY} 的值受到 X 、 Y 分散程度所影响，其单位未必有意义。

于是，定义 X 与 Y 的相关系数：

$$r = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sigma_X \sigma_Y}$$


$$r = \frac{\frac{1}{n} \sum_{i=1}^n (x_i y_i) - \bar{x} \bar{y}}{\sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2} \sqrt{\frac{1}{n} \sum_{i=1}^n y_i^2 - \bar{y}^2}}$$

$$\begin{aligned} \sigma_{XY} &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ &= \frac{1}{n} \sum_{i=1}^n (x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{x} \cdot \bar{y}) \\ &= \frac{1}{n} \left[\sum_{i=1}^n (x_i y_i) - \bar{y} \sum_{i=1}^n (x_i) - \bar{x} \sum_{i=1}^n (y_i) + \bar{x} \cdot \bar{y} \sum_{i=1}^n 1 \right] \\ &= \frac{1}{n} \left[\sum_{i=1}^n (x_i y_i) - \bar{y} (n\bar{x}) - \bar{x} (n\bar{y}) + n(\bar{x} \cdot \bar{y}) \right] \\ &= \frac{1}{n} \sum_{i=1}^n (x_i y_i) - \bar{x} \cdot \bar{y} \end{aligned}$$



- $|r| = 1$ 表示完全相关,
- $0.7 \leq |r| < 1$ 表示高度相关,
- $0.3 \leq |r| < 0.7$ 表示中度相关,
- $0 < |r| < 0.3$ 表示低度相关。


下列 5 个散布图中： x, y 的相关系数依次为 r_a, r_b, r_c, r_d, r_e



问 r_a, r_b, r_c, r_d, r_e 之大小顺序为下列何者？

- (A) $r_a < r_b < r_c < r_d < r_e$ (B) $r_a > r_b > r_c > r_d > r_e$
 (C) $r_b < r_e < r_c < r_d < r_a$ (D) $r_d < r_b < r_e < r_a < r_b$

下图中，有五组数据，每组各有六个资料点



设各组的相关系数由左至右分别为 r_1, r_2, r_3, r_4, r_5 ，则下列何者为假？


- (A) $r_1 = 0$ (B) $r_2 = 0$ (C) $r_3 = 0$ (D) $r_4 = 1$ (E) $r_5 = -1$

a)下表为10名学生的期末成绩和该学期上课缺课节数的统计资料：





学生	甲	乙	丙	丁	戊	己	庚	辛	壬	癸
缺课节数	1	3	5	5	2	4	3	4	2	1
期末成绩	95	75	55	55	65	65	75	85	95	95

i) 作缺课节数 X 与期末成绩 Y 的散布图；(x 轴以二格代表1节， y 轴以一格代表10分)

ii) 求缺课节数 X 、期末成绩 Y 的相关系数，并判定其相关程度。(答案准确至五位小数)



缺课节数 X 与期末成绩 Y 的散布图



a)下表为10名学生的期末成绩和该学期上课缺课节数的统计资料:

学生	甲	乙	丙	丁	戊	己	庚	辛	壬	癸
缺课节数	1	3	5	5	2	4	3	4	2	1
期末成绩	95	75	55	55	65	65	75	85	95	95

$$*推荐 r = \frac{\sum x_i y_i - \bar{x} \bar{y}}{\sqrt{\left(\sum x_i^2 - \bar{x}^2 \right) \left(\sum y_i^2 - \bar{y}^2 \right)}}$$

ii)求缺课节数 X 、期末成绩 Y 的相关系数,并判定其相关程度。(答案准确至四位小数)

x_i	y_i	x_i^2	y_i^2	$x_i y_i$
1	95	1	9025	95
3	75	9	5625	225
5	55	25	3025	275
5	55	25	3025	275
2	65	4	4225	130
4	65	16	4225	260
3	75	9	5625	225
4	85	16	7225	340
2	95	4	9025	190
1	95	1	9025	95
$\sum x_i = 30$	$\sum y_i = 760$	$\sum x_i^2 = 110$	$\sum y_i^2 = 60050$	$\sum x_i y_i = 2110$

$$\bar{x} = \frac{30}{10} = 3$$

$$\bar{y} = \frac{760}{10} = 76$$

$$r = \frac{\frac{2110}{10} - 3(76)}{\left(\sqrt{\frac{110}{10} - 3^2} \right) \left(\sqrt{\frac{60050}{10} - 76^2} \right)}$$

$$= -0.7944$$

$$\because 0.7 \leq |r| < 1$$

$\therefore$ 高度负相关


练习27.1—2,3

27.2 回归直线 Pg. 283

Regression Line

回归直线 (Regression line)

当 X 与 Y 直线相关时，将 X 视为自变量， Y 与 X 之间的关系可用直线方程式表示，此直线成为回归直线。在 X 与 Y 的散布图中，回归直线未必经过所有点。



设回归直线为 $\hat{y} = \alpha + \beta x$, 其中 $\hat{y}$ (读作 y -hat) 表示回归直线上的值以区分观察值 y .


设有 X 与 Y 的数据 n 组 (见图), $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, 令 $e_i = y_i - \hat{y}_i$.

e_i 称为残差 (residual), 其绝对值表示第 i 个观测值沿着 y 轴方向到回归直线的距离。

这些绝对值总和越小, 回归直线越接近数据点。由于平方的运算比绝对值容易处理,

因此数学家提出选择 α 及 β 的值, 使得残差的平方与 $\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ 最小, 此种方

法称为最小平方法 (least squares method)。



设 X 与 Y 的平均数分别为 $\bar{x}$ 及 $\bar{y}$ 。

以下我们不进行证明，直接给出回归直线的方程式：

$$\text{回归直线方程式: } \hat{y} - \bar{y} = \frac{\sigma_{XY}}{\sigma_X^2} (x - \bar{x})$$

从上述的方程式可以看到，回归直线一定经过点 $(\bar{x}, \bar{y})$ 。

注：

从数据中得到回归直线的过程称为数据建模(*data modelling*),

所得到的回归直线方程式是一种统计模型(*statistical model*)。

在中学阶段，我们只简单介绍回归分析的思路及应用，

而不深入探讨其背后的理论。

b)承接a)题，下表为10名学生的期末成绩和该学期上课缺课节数的统计资料：

学生	甲	乙	丙	丁	戊	己	庚	辛	壬	癸
缺课节数	1	3	5	5	2	4	3	4	2	1
期末成绩	95	75	55	55	65	65	75	85	95	95

i) 以上课缺课节数为自变量，求回归直线的方程式。

ii)若有一位同学该学期上课缺课6节，推测他在期末的成绩。(答案准确至整数)

i)已知 $\bar{x} = 3$, $\bar{y} = 76$

$$\sum_{i=1}^{10} x_i^2 = 110, \sum_{i=1}^{10} y_i^2 = 2110$$

$$\frac{\sigma_{XY}}{\sigma_X^2} = \frac{\frac{2110}{10} - 3(76)}{\left(\sqrt{\frac{110}{10} - 3^2}\right)^2} = -8.5$$

$$\hat{y} - 76 = -8.5(x - 3)$$

$$\hat{y} = -8.5x + 101.5$$

回归直线方程式为 $\hat{y} = -8.5x + 101.5$

$$\text{ii)当 } x = 6, \text{ 代入 } \hat{y}, \text{ 得 } \hat{y} = -8.5(6) + 101.5 \\ = 50.5$$

$\therefore$ 推测出期末考成绩为51分左右

一般上，回归直线所作得推出并没有外延性，即所预测得数据超过原始数据范围，则无法确保预测值得可靠性。

如：当 $x = 0$ ，预测值 $\hat{y} = 101.5$ 不合理

c)假设高二某班期末考的数学 x 、物理 y 成绩平均分分别为70、65，标准差分别为8、10，且两科成绩的相关系数为0.8，

i)数学 x 与物理 y 的回归直线方程式为

$$\hat{y} = x - 5$$

$$i) \bar{x} = 70, \bar{y} = 65$$

$$\sigma_x = 8, \sigma_y = 10$$

$$r = 0.8$$

$$\frac{\sigma_{xy}}{8(10)} = 0.8$$

$$\sigma_{xy} = 64$$

$$\frac{\sigma_{xy}}{\sigma_x^2} = \frac{64}{(8)^2} = 1$$

$$\hat{y} - 65 = 1(x - 70)$$

$$\hat{y} = x - 5$$

ii)回归直线的斜率意义为斜率代表数学成绩每增加一分，物理成绩的增量。

iii)若某学生的数学分数为51分，预测其物理分数为46分。

当 $x = 51$, 代入 $\hat{y} = x - 5$, 得 $\hat{y} = 46$

iv)承接上题，某学生的物理考获49分，预测值与实际值的误差百分率为6.12%。

$$\text{误差率} = \frac{|46 - 49|}{49} \times 100\% = 6.12\%$$

d)某肥皂厂商欲推出一种新产品。在上市前以不同的单价 x (单位：元)

调查市场的需求量 y (单位：万)，调查结果如下：

x	8	9	10	11	12
y	11	12	10	8	9

求以单价 x 为自变量的回归直线，据此，若单价为15元，则市场的需求量预估为多少盒？

x_i	y_i	x_i^2	$x_i y_i$
8	11	64	88
9	12	81	108
10	10	100	100
11	8	121	88
12	9	144	108
50	50	510	492

练习27.2—1,2

$$\bar{x} = \frac{50}{5} = 10, \quad \bar{y} = \frac{50}{5} = 10$$

$$\sigma_x = \sqrt{\frac{510}{5} - 10^2} = \sqrt{2}$$

$$\sigma_{xy} = \frac{492}{5} - 10(10) = -\frac{8}{5}$$

$$\frac{\sigma_{xy}}{\sigma_x^2} = \frac{\frac{8}{5}}{(\sqrt{2})^2} = -\frac{4}{5}$$

$$\hat{y} - 10 = -\frac{4}{5}(x - 10)$$

$$5\hat{y} = -4x + 90$$

当 $x = 15$ ，则 $\hat{y} = 6$

$\therefore$ 回归直线方程式为 $5\hat{y} = -4x + 90$ ，预估6万盒